

Caso práctico BreastDCEDL

Predicción de respuesta patológica completa con DCE-MRI

Inteligencia Artificial y Deep Learning

Reto: construir una CNN desde cero y convertirla en una aplicación clínica demostrativa robusta.

1. Por qué se estudia este problema

El cáncer de mama no es una única enfermedad: distintos tumores presentan características biológicas y respuestas al tratamiento diferentes. En pacientes seleccionadas, el equipo médico administra **tratamiento neoadyuvante**, es decir, tratamiento sistémico antes de la cirugía. Este enfoque permite reducir el tumor, tratar precozmente enfermedad microscópica y observar si el tumor responde.

Sin embargo, no todas las pacientes responden igual. Poder estimar la respuesta *antes* de iniciar el tratamiento es un problema importante de investigación: podría ayudar en el futuro a estratificar riesgo, diseñar ensayos, investigar tratamientos personalizados y detectar grupos con baja probabilidad de respuesta. Este caso es educativo y no autoriza decisiones médicas.

2. Qué significa realmente pCR

Las siglas pCR vienen de *pathological Complete Response*. En español se habla de **respuesta patológica completa**. La idea es sencilla. Primero se administra el tratamiento. Después se extrae tejido mediante cirugía o biopsia. Finalmente, un especialista en anatomía patológica observa ese tejido al microscopio y busca células cancerosas residuales.

En este caso, pCR significa que después del tratamiento no se encuentra cáncer invasivo residual en el tejido evaluado de la mama y los ganglios regionales, según la definición utilizada por el estudio. No basta con que el tumor parezca haber desaparecido en una resonancia. La palabra *patológica* indica que la respuesta se determina estudiando tejido [3].

La variable utilizada por el modelo es:

$$y = 1 \iff \text{pCR}, \quad y = 0 \iff \text{no pCR}.$$

Aquí, una pCR positiva es un resultado favorable del tratamiento. No quiere decir que “el cáncer sea positivo”. Quiere decir que la respuesta completa sí se ha observado. Por el contrario, no pCR significa que queda enfermedad invasiva residual. Puede quedar poca o mucha. La etiqueta binaria no expresa esa cantidad.

Una predicción de 0,82 significa que el modelo estima $P(\text{pCR} = 1) = 0,82$ para esa entrada. No significa 82 % de supervivencia. Tampoco significa 82 % de curación. Mucho menos demuestra que pueda evitarse una operación.

La pCR es relevante como indicador temprano de respuesta y como variable de investigación, aunque su interpretación depende del subtipo tumoral y del contexto clínico. Por ello una aplicación debe mostrar incertidumbre y limitaciones, no una conclusión terapéutica.

2.1. Qué sucede si la paciente se opera

Después del tratamiento neoadyuvante se realiza la cirugía prevista. El tejido extraído permite comprobar qué ha ocurrido. Si no se encuentra cáncer invasivo residual, se registra pCR. Si todavía se encuentran células de cáncer invasivo, se registra no pCR. La cirugía sigue teniendo funciones de tratamiento local y de evaluación patológica. Una predicción de una red neuronal no sustituye esas funciones.

Alcanzar pCR suele asociarse con un pronóstico más favorable en determinados subtipos de cáncer de mama. Aun así, pCR no equivale a curación garantizada. El seguimiento médico continúa y las decisiones posteriores dependen de muchos datos, no solo de esta etiqueta.

Cuando queda enfermedad residual, el equipo médico conoce mejor cuánto tumor ha resistido al tratamiento. Esa información puede influir en la valoración del riesgo y en el tratamiento posterior. El modelo de esta práctica no decide nada de eso.

2.2. Qué sucede si no se opera

Si no se obtiene tejido suficiente mediante cirugía o una biopsia adecuada, no se puede confirmar la respuesta patológica completa de la misma forma. Una resonancia puede sugerir que el tumor ha desaparecido y aun así pueden quedar focos microscópicos que la imagen no detecte.

Por esta razón, una probabilidad alta calculada por la aplicación no debe usarse para recomendar que una paciente no se opere. La posibilidad de reducir u omitir cirugía se investiga en estudios clínicos muy controlados. Requiere evidencia adicional, protocolos específicos y decisiones de equipos médicos especializados. No es una conclusión que pueda obtenerse de este ejercicio.

2.3. Cómo aprende la CNN

Hay tres momentos distintos. La DCE-MRI se realiza antes del tratamiento, cuando la respuesta todavía no se conoce. Después llega el tratamiento neoadyuvante. La etiqueta real se obtiene más tarde al estudiar el tejido. La CNN aprende con casos anteriores e intenta relacionar la imagen inicial con el resultado posterior. Para una paciente nueva solo produce una **estimación**. No observa el futuro.

Una probabilidad alta tampoco garantiza pCR y una probabilidad baja no la excluye. Si se usa un umbral de 0,50 pueden existir verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. Por eso deben estudiarse calibración, sensibilidad, especificidad y el intervalo de incertidumbre, además de ROC-AUC. El umbral no debe escogerse mirando el conjunto test.

2.4. Dos ejemplos hipotéticos

Considérense dos pacientes ficticias con exploraciones realizadas antes del tratamiento. No son casos clínicos reales y la ilustración no permite diagnosticar.

Ejemplo A. Estimación alta. La aplicación devuelve $P(\text{pCR} = 1) = 0,84$. La paciente recibe el tratamiento previsto y se opera. En el estudio patológico no se encuentra enfermedad invasiva residual según la definición del dataset. El resultado observado es pCR. La predicción habría sido un verdadero positivo. Conocer una estimación así antes de la cirugía podría ser útil en investigación para planificar seguimiento, estratificar un ensayo o informar una conversación multidisciplinar. **No habría demostrado que la cirugía fuese innecesaria.** La cirugía y la anatomía patológica son precisamente las que permiten confirmar la respuesta en este planteamiento.

Ejemplo B. Estimación baja. La aplicación devuelve $P(\text{pCR} = 1) = 0,18$. Después del tratamiento y la cirugía se identifica tumor residual. El resultado es no pCR. Sería un verdadero negativo respecto de la clase pCR. Si un modelo estuviese validado de manera prospectiva, una señal de baja respuesta podría investigarse para intensificar monitorización, incluir a la paciente en un ensayo o estudiar alternativas. Este ejercicio no aporta esa validación y nunca debe producir automáticamente un cambio terapéutico.




Figura 1: Ejemplos educativos. A la izquierda se representa una estimación alta y una pCR confirmada. A la derecha aparece una estimación baja y enfermedad residual. La predicción se realiza antes. El resultado se conoce después del tratamiento y de la cirugía.

También son posibles los dos errores: una estimación alta con tumor residual (falso positivo) y una estimación baja en una paciente que finalmente alcanza pCR (falso negativo). El alumnado deberá explicar las consecuencias de ambos y no presentar la probabilidad como certeza.

3. Del proceso clínico al modelo




Figura 2: La imagen se obtiene antes del tratamiento. La etiqueta pCR se conoce después.

4. Qué aporta la DCE-MRI

La resonancia magnética dinámica con contraste (DCE-MRI) adquiere varias imágenes del mismo tejido a lo largo del tiempo. El contraste modifica la intensidad según la perfusión y permeabilidad vascular. BreastDCEDL MinCrop proporciona tres fases centradas en el tumor:

- **PRE:** antes de administrar contraste.
- **EARLY:** fase postcontraste temprana.
- **LATE:** fase postcontraste tardía.

Se alinean anatómicamente y se apilan como canales de un tensor $3 \times 256 \times 256$. La CNN puede aprender conjuntamente forma, textura y cambios de realce, pero también puede aprender artefactos o diferencias entre cohortes. Esta posibilidad debe investigarse críticamente.

Cada fase se entrega como una imagen PNG independiente en escala de grises, con la fase escrita en el nombre del fichero (`_PRE`, `_EARLY`, `_LATE`). Esto permite inspeccionar el conjunto con el explorador de archivos y saber de un vistazo qué imagen corresponde a cada momento. Se descartó almacenar las tres fases en un único PNG en color (R=PRE, G=EARLY, B=LATE): ocupa exactamente lo mismo, pero oculta que dentro hay tres instantes distintos y obliga a consultar la documentación para saber cuál es la imagen previa al contraste.

Conviene subrayar una distinción que suele confundirse: el sufijo `z012` indica *dónde* —la altura del corte axial dentro del volumen— mientras que el sufijo de fase indica *cuándo*. Cortes consecutivos no son instantes consecutivos.

Al apilar las tres fases se obtiene un tensor de tres canales, pero **esos canales no son colores**. En consecuencia no debe aplicarse normalización de ImageNet, ni aumentado de color, ni `ImageFolder`; y cualquier transformación geométrica debe aplicarse a las tres fases a la vez, porque desalinearlas destruye la información de realce, que es la señal del problema.




Figura 3: Ejemplo real del formato entregado. Las intensidades están normalizadas por volumen para aprendizaje, no para diagnóstico.

5. Dataset BreastDCEDL

El caso se basa en BreastDCEDL, descrito por Fridman y colaboradores [1]. Integra DCE-MRI de I-SPY1, I-SPY2 y Duke, estandariza volúmenes NIfTI, variables clínicas y particiones reproducibles. La versión MinCrop recorta el entorno tumoral a 256×256 y conserva PRE, EARLY y LATE.

El conjunto completo incluye aproximadamente 2.070 pacientes. Para pCR hay unas 1.452 etiquetas conocidas: 428 positivas y 1.024 negativas. Existe un desbalance relevante. Una accuracy alta puede ocultar una sensibilidad insuficiente.

El dataset docente deriva aproximadamente diez cortes relevantes por paciente. En I-SPY1 e I-SPY2 se priorizan los de mayor superficie tumoral en la máscara 3D. Duke no dispone de segmentación completa: se eligen cortes centrales dentro de los límites tumorales publicados entre `mask_start` y `mask_end`. Esta diferencia entre cohortes es una posible fuente de sesgo que debe discutirse. Cada fase se almacena como un PNG de 8 bits en escala de grises y 256×256 , en la ruta `dataset/<split>/<patient_id>/<sample_id>_<FASE>.png`. Los ficheros se agrupan en una carpeta por paciente para que la unidad estadística del problema quede explícita en la propia estructura del conjunto. Cada fichero se carga como `[256, 256]` en `uint8`; apilando las tres fases en el orden PRE, EARLY, LATE y dividiendo entre 255 se obtiene el `[3, 256, 256]` que espera la red.

Las intensidades se recortaron a los percentiles 1 y 99 calculados sobre las tres fases *conjuntamente*, y se escalan a `[0, 1]` con esa única ventana. Compartir la ventana entre fases es lo que permite que `EARLY-PRE` represente realce de contraste: si cada fase se normalizase por separado, la inyección de contraste elevaría su propio percentil 99 y la intensidad media de `EARLY` resultaría


inferior a la de PRE, produciendo un realce negativo sobre la mama que es físicamente imposible. El paso a 8 bits aplica después una escala fija e idéntica para todos los cortes, de modo que esa normalización se conserva y solo se discretiza.

Como consecuencia, el alumnado puede verificar el orden de las fases a partir de la fisiología: al inyectar el contraste el tejido se ilumina, de modo que la intensidad media debe cumplir $PRE < EARLY$. Medido sobre 120 pacientes, se verifica en el 100 % de los casos.

En cambio LATE solo supera a EARLY en el 83 % de las pacientes. Ese descenso no es un defecto del conjunto sino el *lavado* del contraste (*washout*), un patrón de la curva de realce que en la práctica clínica se asocia a lesiones sospechosas y que constituye información potencialmente útil para el modelo. El error de cuantización resultante es de $1/255$ sobre el realce $EARLY - PRE$, unas 32 veces menor que la mediana del realce medido dentro del tejido, por lo que no compromete la señal de interés.


El CSV `samples.csv` incluye `sample_id`, `patient_id`, `split`, las tres rutas (`path_pre`, `path_early`, `path_late`), `slice_index`, `fold` y etiqueta cuando está disponible.

Como esta organizado el dataset: el nombre dice DONDE (z) y CUANDO (fase)



z012 ... z021 es DONDE: la altura del corte. La resonancia se rebana de abajo arriba.

Son posiciones anatómicas, NO momentos en el tiempo.



PRE - media en tejido: 0.346

EARLY - media en tejido: 0.448

LATE - media en tejido: 0.476

El sufijo del nombre es CUANDO: un fichero por momento. Para ver la imagen previa al contraste, abre la que termina en _PRE.

Los tres son el mismo corte z016. Al inyectar el contraste el tejido se ilumina: por eso EARLY supera a PRE.

Figura 4: Organización del conjunto. El índice *z* indica *dónde* —la altura del corte axial— y el sufijo de fase indica *cuándo*. Cortes consecutivos no son instantes consecutivos: cada corte existe en las tres fases, en tres ficheros distintos.

6. Separación y evaluación

La unidad estadística es la paciente, no el corte. Ningún `patient_id` puede aparecer en más de un `split`. De lo contrario existiría *data leakage*: el modelo reconocería anatomía de una paciente vista durante entrenamiento.

Conjunto	Quién lo recibe	Etiqueta pCR
train	alumnado	sí
validation	solo profesorado	sí
test	alumnado, para evaluación final	sí

El alumnado recibe train y test con sus etiquetas. Debe usar test para calcular las métricas finales y la matriz de confusión, pero no para ajustar el modelo ni los hiperparámetros. El profesorado conserva validation como conjunto privado para la evaluación en directo. Para ajustar hiperparámetros, el alumnado puede crear una partición interna a partir de train. Esa partición también debe hacerse por paciente.

La edición local generada contiene 1.450 pacientes y 14.470 cortes: 1.097 pacientes en train, 177 en la validación privada y 176 en test. Dos pacientes Duke se excluyeron porque el volumen correspondiente a la fase tardía indicada en el metadato no estaba presente. La exclusión queda registrada en `excluded_patients.csv`. El número de cortes puede ser menor de diez en volúmenes con una región axial disponible muy corta.

7. Objetivo técnico obligatorio

Construir una **CNN 2D completamente desde cero** con PyTorch. No se permite ResNet, EfficientNet, VGG, DenseNet, modelos preentrenados ni transfer learning. La salida será un único *logit*. Durante entrenamiento se utilizará `BCEWithLogitsLoss`. Deben compararse pérdida normal y ponderada:

$$\text{pos_weight} = N_0/N_1.$$

La arquitectura, inicialización, regularización, optimizador, tasa de aprendizaje, tamaño de lote, épocas, semilla y criterio de parada deben justificarse y guardarse.

8. Uso recomendado de GPU

Se recomienda utilizar GPU para el entrenamiento porque las operaciones convolucionales pueden ser costosas. Su uso no es obligatorio. Cuando se utilice, el informe debe indicar el dispositivo, la versión del entorno, la memoria máxima, el tiempo por época, el tiempo total y el tamaño de lote. También se puede comparar una ejecución corta en CPU y GPU. En ese caso se calculará $\text{speedup} = t_{CPU}/t_{GPU}$.

9. Aplicación web final

Además del experimento, cada estudiante desarrollará una aplicación web robusta con Streamlit, Gradio o una tecnología equivalente. La aplicación deberá estar desplegada y accesible mediante una URL durante la exposición. No se aceptará una aplicación que solo funcione en el ordenador local del estudiante.

Debe permitir cargar las tres fases de un corte del conjunto, o seleccionar un ejemplo, y mostrar PRE, EARLY y LATE por separado además del mapa de realce. Tras validar forma, tipo y valores, ejecutará el modelo y mostrará:

- probabilidad de pCR y clase según el umbral elegido.
- Umbral utilizado y versión o checksum del modelo.
- Dispositivo de inferencia y tiempo de respuesta.
- Parámetros principales del entrenamiento y métricas internas.

- Mensajes claros ante archivos corruptos, imágenes que no sean PNG de 256×256 , o fases ausentes o duplicadas.
- aviso visible de uso educativo, incertidumbre y ausencia de validez clínica.

La aplicación no aceptará rutas arbitrarias del sistema. Tampoco ejecutará contenido subido. Debe limitar el tamaño y el formato de los archivos. La predicción se ejecutará con `model.eval()` y sin gradientes. El resultado ha de ser reproducible. La validación privada del profesor y sus etiquetas no pueden quedar incluidas en un repositorio público ni dentro de la aplicación.

10. Trabajo individual y publicación

Este caso se realiza de forma individual. Cada estudiante debe entrenar su propio modelo, tomar sus decisiones, desarrollar su aplicación y defender sus resultados. La autoría del repositorio y de la aplicación debe corresponder al estudiante.

Se permite publicar el trabajo en un repositorio personal. El repositorio puede incluir el código, la configuración, los pesos del modelo, el informe, las cinco diapositivas y el enlace a la aplicación web. También puede incluir ejemplos del dataset siempre que se mantengan la licencia CC BY-NC 4.0, la atribución a BreastDCEDL y las referencias de las fuentes originales. Las etiquetas privadas, la validación del profesor y cualquier fichero de verdad terreno no pueden publicarse. Para datos de gran tamaño se recomienda utilizar releases o almacenamiento específico, en lugar de incorporarlos al historial normal de Git.

11. Presentación en clase

Cada estudiante expondrá su trabajo con **exactamente cinco diapositivas**:

1. Problema clínico, significado de pCR y objetivo del proyecto.
2. Preparación de datos, separación por paciente y análisis de clases.
3. Arquitectura de la CNN construida desde cero, con tamaños y parámetros.
4. Entrenamiento, decisiones tomadas y resultados internos.
5. Aplicación web, demostración, limitaciones y conclusiones.

Las diapositivas deben explicar la solución del estudiante. No deben convertirse en una copia del código ni en una sucesión de capturas sin análisis. El estudiante debe poder responder preguntas sobre la arquitectura y el proceso de entrenamiento.

12. Evaluación de la aplicación

El profesorado seleccionará al azar **cinco muestras de la validación privada pertenecientes a cinco pacientes distintos**. La selección se realizará durante la sesión o justo antes de comenzar. El estudiante no conocerá previamente esas muestras ni sus etiquetas.

Las cinco muestras se cargarán una a una en la aplicación web durante la defensa. La aplicación deberá procesarlas sin modificaciones de código, sin volver a entrenar y sin reiniciar el despliegue. Para cada muestra se guardará la probabilidad mostrada, el umbral y la clase predicha. Después el profesor revelará la etiqueta real y registrará el resultado.

También se verificará que la predicción coincida con la obtenida por el pipeline, que no haya normalización distinta entre entrenamiento e inferencia y que los errores se gestionen bien. Cinco muestras no son suficientes para estimar de forma fiable el rendimiento clínico. Esta prueba evalúa principalmente que la aplicación funcione con datos nuevos y que las predicciones sean reproducibles. El profesorado podrá calcular por separado las métricas sobre un conjunto oculto mayor.

13. Plan de trabajo y entregables

1. Auditar pacientes, clases, canales y rangos. Visualizar ejemplos.
2. Construir y justificar la CNN desde cero.
3. Entrenar baselines y estudiar desbalance, overfitting y umbral.
4. Fijar el modelo usando train y una validación interna separada por paciente.
5. Implementar y probar la aplicación con entradas válidas e inválidas.
6. Entregar repositorio reproducible, pesos, configuración y URL de la aplicación web.
7. Preparar las cinco diapositivas y realizar la exposición en clase.
8. Completar la evaluación en directo con cinco muestras privadas aleatorias.

14. Preguntas para la discusión

¿Qué error es más relevante en este escenario y por qué? ¿Cambia la respuesta según el uso previsto? ¿La red aprende biología tumoral o diferencias entre cohortes? ¿Cómo afecta tener diez observaciones correlacionadas por paciente? ¿Está calibrada la probabilidad? ¿Qué evidencia faltaría para estudiar utilidad clínica, equidad y generalización externa?

15. Ética, límites y licencia

Son imágenes desidentificadas para docencia e investigación. No se permite reidentificación, diagnóstico ni recomendación terapéutica. Debe conservarse la atribución y licencia CC BY-NC 4.0. Un buen resultado retrospectivo no demuestra seguridad, causalidad ni utilidad clínica prospectiva.

Referencias

- [1] N. Fridman et al., “BreastDCEDL: A standardized deep learning-ready breast DCE-MRI dataset of 2,070 patients”, *Scientific Data*, 2026. DOI: [10.1038/s41597-026-06589-6](https://doi.org/10.1038/s41597-026-06589-6).
- [2] N. Fridman et al., *BreastDCEDL: A Deep Learning-Ready Breast DCE-MRI Dataset*, Zenodo. DOI: [10.5281/zenodo.18114231](https://doi.org/10.5281/zenodo.18114231).
- [3] National Cancer Institute, “Pathologic complete response”, *Dictionary of Cancer Terms*. <https://www.cancer.gov/publications/dictionaries/cancer-terms/def/pathologic-complete-response>.
- [4] U.S. Food and Drug Administration, “Pathological Complete Response in Neoadjuvant Treatment of High-Risk Early-Stage Breast Cancer”, 2020. <https://www.fda.gov/regulatory-information/search-fda-guidance-documents/pathological-complete-response-neoadjuvant-treatment-high-risk-early-stage-breast-cancer-u>